

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA



Thực Tập 1 + 2

Đề cương nghiên cứu tổng quan

**Nghiên cứu và đề xuất phương pháp truy xuất
sản phẩm thời trang đa phương thức có điều kiện
dựa trên mô hình Vision-Language**

Giảng viên: PGS.TS. Võ Thị Ngọc Châu
Học viên: Võ Thị Bích Phượng - 2470570

TP. HỒ CHÍ MINH, THÁNG 9 2026

Mục lục

1	Bối cảnh và Đặt vấn đề	2
2	Mục tiêu và Phạm vi nghiên cứu	2
2.1	Mục tiêu tổng quát	2
2.2	Mục tiêu cụ thể	2
2.3	Phạm vi nghiên cứu	3
3	Tổng quan tình hình nghiên cứu (Literature Review)	3
3.1	Tiếp cận đơn phương thức (Unimodal Retrieval)	3
3.2	Mô hình nền tảng Thị giác – Ngôn ngữ trong lĩnh vực thời trang	3
3.3	Truy xuất hình ảnh kết hợp điều kiện văn bản (Composed Image Retrieval)	3
3.4	Bảng tổng hợp tài liệu tham khảo theo nhóm	4
4	Khoảng trống nghiên cứu và Phương pháp đề xuất	5
4.1	Khoảng trống nghiên cứu (Research Gap)	5
4.2	Phương pháp đề xuất	5
5	Dữ liệu và Kế hoạch thực nghiệm	6
5.1	Dữ liệu (Dataset)	6
5.2	Phương pháp so sánh (Baselines / SOTA)	6
5.3	Ablation Study	6
5.4	Đánh giá đo lường (Evaluation Metrics)	7
6	Rủi ro và Phương án dự phòng	8
7	Dự kiến sản phẩm bàn giao và Ý nghĩa	8
7.1	Dự kiến sản phẩm bàn giao (Deliverables)	8
7.2	Ý nghĩa khoa học và thực tiễn	9
7.3	Hướng mở rộng ứng dụng (ngoài phạm vi đánh giá chính)	9
8	Tài liệu tham khảo	9

1 Bối cảnh và Đặt vấn đề

Trong lĩnh vực Thương mại điện tử (TMDT) ngành hàng dệt may và thời trang, người dùng cuối cũng như đối tác mua sỉ (B2B buyers/merchandisers) có xu hướng tìm kiếm sản phẩm bằng cách kết hợp một **hình ảnh tham khảo** (reference image) với một **đoạn văn bản điều chỉnh** (modifier text) – ví dụ: “*tìm mẫu quần giống ảnh này nhưng chất liệu denim và form dáng rộng hơn*”. Đây là bài toán **Composed Image Retrieval (CIR)**: truy xuất một ảnh đích (target image) dựa trên một cặp truy vấn (*ảnh, văn bản*) thay vì một truy vấn đơn phương thức.

Về mặt mô hình hóa, bài toán này khó hơn truy xuất ảnh–văn bản thông thường ở chỗ mô hình phải học được một phép biến đổi (transformation) trên không gian đặc trưng: từ vector biểu diễn ảnh gốc, dưới sự điều khiển ngữ nghĩa của văn bản chỉnh sửa, sinh ra một vector truy vấn mới đại diện cho ảnh đích – một dạng suy luận *compositional reasoning* giữa hai phương thức mà các mô hình truy xuất ảnh–văn bản tĩnh (như CLIP nguyên bản) không được thiết kế để xử lý. Trong lĩnh vực thời trang, bài toán càng phức tạp hơn do các thuộc tính cần chỉnh sửa (chất liệu, kiểu wash, chi tiết cắt may) thường rất tinh tế (fine-grained) và không có ranh giới thị giác rõ ràng như các đối tượng thông thường.

Đề tài lựa chọn hướng nghiên cứu này vì ba lý do: (i) có tính thời sự cao trong cộng đồng Computer Vision (các công trình CLIP4Cir, ARTEMIS, FashionVLP đều công bố trong giai đoạn 2021–2022 và vẫn đang được phát triển tiếp); (ii) có sẵn benchmark học thuật chuẩn hóa (FashionIQ) với protocol đánh giá rõ ràng, cho phép đối chiếu trực tiếp với kết quả đã công bố; (iii) khoảng trống nghiên cứu cụ thể (trình bày ở Mục 4) có thể giải quyết trong phạm vi một đề tài Thực Tập 1+2 mà không đòi hỏi hạ tầng tính toán vượt quá khả năng của một học viên.

2 Mục tiêu và Phạm vi nghiên cứu

2.1 Mục tiêu tổng quát

Nghiên cứu, thiết kế và huấn luyện một kiến trúc mô hình cho bài toán Composed Image Retrieval trong lĩnh vực thời trang, kết hợp một mô hình nền tảng Vision-Language đã được tinh chỉnh theo miền (Fashion-CLIP) làm backbone trích xuất đặc trưng với một **Combiner Network dựa trên cơ chế Cross-Attention**, đồng thời đánh giá định lượng phương pháp đề xuất so với các công trình SOTA hiện có trên benchmark chuẩn FashionIQ.

2.2 Mục tiêu cụ thể

- Khảo sát và phân loại các hướng tiếp cận hiện có cho bài toán Composed Image Retrieval, xác định rõ khoảng trống về mặt kiến trúc mô hình và tín hiệu giám sát (supervision signal).
- Tinh chỉnh (fine-tune) Fashion-CLIP trên dữ liệu FashionIQ/DeepFashion để làm backbone trích xuất đặc trưng ảnh và văn bản.
- Thiết kế và huấn luyện một Combiner Network dựa trên Cross-Attention, thay thế cơ chế cổng phần dư (residual gating) truyền thống của TIRG.
- Thiết kế hàm mất mát kết hợp: contrastive loss ở mức truy vấn tổng thể và một nhánh giám sát phụ trợ (auxiliary supervision) ở mức thuộc tính sản phẩm.
- Thực hiện Ablation Study để định lượng đóng góp riêng lẻ của từng thành phần kiến trúc.

- (f) So sánh định lượng (Recall@10, Recall@50) với các baseline/SOTA: TIRG, CoSMo, ARTEMIS, CLIP4Cir, FashionVLP, và CLIP zero-shot trên FashionIQ.

2.3 Phạm vi nghiên cứu

- **Trong phạm vi:** Thiết kế kiến trúc mô hình, hàm mất mát, quy trình huấn luyện/ablation, và đánh giá thực nghiệm học thuật trên benchmark công khai (FashionIQ là chính; DeepFashion/DeepFashion2/Fashion-Gen là phụ trợ).
- **Ngoài phạm vi:** Triển khai hệ thống Backend production hoàn chỉnh (API Gateway, đồng bộ dữ liệu thời gian thực, hạ tầng phục vụ hàng triệu truy vấn/giây). Các nội dung này chỉ được đề cập ngắn gọn ở Mục 8.3 như một hướng mở rộng ứng dụng khả thi, **không phải** nội dung được thực hiện hay đánh giá trong đề tài. Đề tài cũng không huấn luyện mô hình nền tảng (foundation model) từ đầu, mà chỉ fine-tune trên mô hình đã huấn luyện trước (Fashion-CLIP).

3 Tổng quan tình hình nghiên cứu (Literature Review)

3.1 Tiếp cận đơn phương thức (Unimodal Retrieval)

Các nghiên cứu giai đoạn đầu tách biệt hoàn toàn luồng xử lý văn bản và hình ảnh: văn bản được biểu diễn qua TF-IDF hoặc Word2Vec, trong khi hình ảnh được trích xuất đặc trưng bằng mạng nơ-ron tích chập (CNN) như ResNet. Hạn chế cốt lõi của hướng tiếp cận này là *khoảng trống ngữ nghĩa* (semantic gap) giữa hai luồng dữ liệu độc lập, khiến việc đối sánh chéo (cross-modal matching) trở nên rời rạc và không có cơ chế nào để hợp nhất một truy vấn ảnh với một truy vấn văn bản điều chỉnh đi kèm.

3.2 Mô hình nền tảng Thị giác – Ngôn ngữ trong lĩnh vực thời trang

Sự ra đời của mô hình CLIP [1] đã tạo ra bước đột phá khi ánh xạ đồng thời hình ảnh và văn bản vào chung một không gian vector biểu diễn liên tục (Joint Embedding Space), huấn luyện tương phản (contrastive learning) trên 400 triệu cặp ảnh–văn bản thu thập từ Internet. Tuy nhiên, do được huấn luyện trên dữ liệu tổng quát, CLIP nguyên bản thường bỏ sót các thuộc tính đặc thù ngành may mặc.

Kế thừa CLIP, Fashion-CLIP [2] tiến hành tinh chỉnh (fine-tune) kiến trúc này trên dữ liệu chuyên biệt ngành thời trang, giúp mô hình nhận diện tốt hơn các thuộc tính như chất liệu, kiểu dáng, họa tiết. Theo một hướng khác, Kaleido-BERT [3] đề xuất kiến trúc Transformer huấn luyện trước (pre-training) chuyên biệt cho dữ liệu thời trang thông qua cơ chế Kaleido Patch Generator, cho phép mô hình học các đặc trưng tinh tế (fine-grained features) ở nhiều mức độ chi tiết khác nhau của một sản phẩm. Đây chính là các backbone ứng viên cho bài toán Composed Image Retrieval được trình bày ở Mục 3.3.

3.3 Truy xuất hình ảnh kết hợp điều kiện văn bản (Composed Image Retrieval)

Đây là dòng nghiên cứu trung tâm của đề tài, có thể chia thành ba thể hệ kỹ thuật:

- (i) **Cổng phân dư (Gating/Residual).** Vo et al. [4] đề xuất mạng TIRG (Text Image Residual Gating), nhận đầu vào là vector ảnh gốc và vector văn bản điều chỉnh, tính toán một

cổng phần dư (residual gate) để sinh ra vector đặc trưng đại diện cho sản phẩm mục tiêu:

$$f_{\text{target}} = w_g \odot f_g(f_{\text{img}}, f_{\text{text}}) + w_r \odot f_r(f_{\text{img}}, f_{\text{text}})$$

trong đó f_g là nhánh cổng (gating), f_r là nhánh phần dư (residual), w_g, w_r là trọng số học được. TIRG dùng backbone CNN (ResNet)/LSTM huấn luyện tương đối độc lập với các mô hình nền tảng quy mô lớn.

(ii) **Điều biến nội dung-phong cách và attention tường minh.** CoSMo [5] đề xuất hai bộ điều biến (modulator) tách biệt cho nội dung (content) và phong cách (style) của ảnh, trong khi ARTEMIS [6] đề xuất cơ chế *Text-Explicit Matching* kết hợp với *Implicit Similarity*, cho phép mô hình vừa so khớp tường minh theo từ khóa văn bản, vừa học một độ tương đồng ngầm giữa cặp (ảnh, văn bản) và ảnh đích.

(iii) **Combiner Network trên nền CLIP.** Baldrati et al. [7] (CLIP4Cir) là công trình đầu tiên chứng minh việc xây dựng một Combiner Network nhỏ (vài lớp fully-connected) trên nền đặc trưng CLIP đã fine-tune một phần, đạt kết quả vượt trội so với các mô hình huấn luyện từ đầu như TIRG. Theo hướng transformer, FashionVLP [8] nâng cấp cơ chế Attention để mô hình đối sánh chính xác giữa một cụm từ kỹ thuật (ví dụ: “cổ áo thuyền”, “tay raglan”) với vùng ảnh tương ứng, đồng thời kết hợp thông tin thị giác ở nhiều mức ngữ cảnh (toàn cảnh, vùng cắt, chi tiết crop).

3.4 Bảng tổng hợp tài liệu tham khảo theo nhóm

Bảng 1 tổng hợp các công trình nền tảng, nhấn mạnh *backbone* và *cơ chế fusion* của từng phương pháp – hai trục chính mà Mục 4 sẽ dùng để định vị khoảng trống nghiên cứu.

Bảng 1: Tổng hợp Literature Review theo nhóm chủ đề

Nhóm	Công trình	Backbone / Fusion	Giới hạn đối với bài toán đề tài
Vision-Language Foundation	CLIP [1], Fashion-CLIP [2], Kaleido-BERT [3]	Dual-encoder, contrastive pretrain	Không có cơ chế xử lý truy vấn <i>có điều kiện</i> (ảnh + modifier text)
CIR – Gating	TIRG [4]	CNN/LSTM riêng, residual gate	Không tận dụng không gian embedding đã căn chỉnh sẵn của VLM lớn
CIR – Attention tường minh	CoSMo [5], ARTEMIS [6]	CNN/LSTM riêng, modulator/explicit matching	Backbone chưa được pretrain trên dữ liệu ảnh-văn bản quy mô lớn
CIR – CLIP-based Combiner	CLIP4Cir [7], FashionVLP [8]	CLIP backbone (chưa chuyên biệt thời trang) + combiner nhẹ	Dùng CLIP gốc/backbone tổng quát, chưa kết hợp với VLM đã fine-tune miền thời trang (Fashion-CLIP); supervision chỉ ở mức global contrastive

4 Khoảng trống nghiên cứu và Phương pháp đề xuất

4.1 Khoảng trống nghiên cứu (Research Gap)

Từ Bảng 1, đề tài xác định ba khoảng trống cụ thể ở mức mô hình:

- G1. **Backbone chưa chuyên biệt hóa:** CLIP4Cir và ARTEMIS chứng minh việc xây Combiner Network trên nền một mô hình Vision-Language đã pretrain (CLIP) mang lại lợi ích rõ rệt so với huấn luyện từ đầu (TIRG, CoSMo). Tuy nhiên, các công trình này dùng *CLIP nguyên bản* – vốn đã được Fashion-CLIP [2] chứng minh là bỏ sót nhiều thuộc tính đặc thù ngành may mặc (Mục 3.2). Chưa có công trình nào kết hợp trực tiếp một backbone đã fine-tune theo miền thời trang với kiến trúc Combiner kiểu CLIP4Cir/ARTEMIS.
- G2. **Cơ chế fusion còn đơn giản ở mức biểu diễn ảnh thời trang:** TIRG dùng cổng phần dư tuyến tính; CLIP4Cir dùng vài lớp fully-connected. Trong khi đó, các thuộc tính cần chỉnh sửa trong thời trang thường cục bộ (ví dụ chỉ thay đổi phần cổ áo hoặc chất liệu tay áo) – một cơ chế **Cross-Attention** giữa các token đặc trưng ảnh và token văn bản có tiềm năng mô hình hóa tính cục bộ này tốt hơn phép biến đổi toàn cục.
- G3. **Thiếu giám sát ở mức thuộc tính:** Tất cả các phương pháp ở Bảng 1 chỉ tối ưu contrastive loss ở mức toàn cục (truy vấn hợp nhất khớp với đúng một ảnh đích), trong khi FashionIQ và DeepFashion đều có sẵn nhãn thuộc tính/danh mục có thể dùng làm tín hiệu giám sát phụ trợ (auxiliary supervision) nhưng chưa được khai thác trong các công trình CIR nêu trên.

4.2 Phương pháp đề xuất


Dựa trên ba khoảng trống G1–G3, đề tài đề xuất kiến trúc **Fashion-CLIP Cross-Attention Combiner (FC²AC)**, minh họa ở Hình 1, gồm ba thành phần:

- **Backbone (giải quyết G1):** Fashion-CLIP [2] đã fine-tune, dùng làm Image Encoder cho cả ảnh tham khảo và ảnh đích, và Text Encoder cho văn bản điều chỉnh. Trọng số hai encoder được chia sẻ (shared weights) với CLIP4Cir để đảm bảo so sánh công bằng khi đánh giá ở Mục 5.
- **Combiner Network (giải quyết G2):** Một khối Transformer nhỏ thực hiện Cross-Attention hai chiều: token đặc trưng ảnh tham khảo đóng vai trò Query, token đặc trưng văn bản đóng vai trò Key/Value (và ngược lại ở lớp kế tiếp), sinh ra một vector truy vấn hợp nhất (composed query embedding) f_c nằm trong cùng không gian với vector ảnh đích.
- **Hàm mất mát kết hợp (giải quyết G3):**

$$\mathcal{L} = \mathcal{L}_{\text{InfoNCE}}(f_c, f_{\text{tgt}}) + \lambda \mathcal{L}_{\text{attr}}(f_c, y_{\text{attr}})$$

trong đó $\mathcal{L}_{\text{InfoNCE}}$ là contrastive loss trong batch giữa vector truy vấn hợp nhất f_c và vector ảnh đích f_{tgt} ; $\mathcal{L}_{\text{attr}}$ là cross-entropy loss của một nhánh phân loại phụ trợ dự đoán nhãn thuộc tính đích y_{attr} (category/attribute có sẵn trong nhãn dataset) từ f_c ; λ là trọng số cân bằng, được xác định bằng grid search ở Mục 5.3.

Ghi chú: Tại thời điểm suy luận (inference), vector f_c có thể được dùng làm truy vấn cho một chỉ mục Approximate Nearest Neighbor (ví dụ FAISS [14] hoặc HNSW [15]) để tìm ảnh đích gần nhất trong catalog. Đây là một ứng dụng minh họa của mô hình, được trình bày thêm ở Mục 8.3, không thuộc phạm vi đánh giá chính của đề tài.



Hình 1: Kiến trúc mô hình đề xuất FC²AC: Fashion-CLIP backbone + Cross-Attention Combiner + hàm mất mát kết hợp (InfoNCE + Auxiliary Attribute Loss).

5 Dữ liệu và Kế hoạch thực nghiệm

5.1 Dữ liệu (Dataset)

Bảng 2 liệt kê các bộ dữ liệu công khai dự kiến sử dụng. FashionIQ là dataset chính (dùng để huấn luyện và đánh giá Combiner Network); các dataset còn lại phục vụ tiền huấn luyện/fine-tune backbone và kiểm định khả năng tổng quát hóa.

Bảng 2: Danh mục Dataset sử dụng trong thực nghiệm

Dataset	Quy mô	Vai trò trong đề tài
FashionIQ [9]	77.684 ảnh, 30.134 triplet	Dataset chính: huấn luyện và đánh giá Combiner Network trên 3 category (Dress, Shirt, Toptee)
DeepFashion [10]	~800K ảnh	Fine-tune backbone Fashion-CLIP; nguồn nhãn category/attribute cho $\mathcal{L}_{attr}$
DeepFashion2 [11]	491K ảnh, 801K item	Kiểm định độ bền (robustness) của backbone trên ảnh đa góc chụp
Fashion-200K [12]	~200K ảnh + mô tả	Đánh giá bổ sung khả năng tổng quát hóa của Combiner ngoài FashionIQ
Fashion-Gen [13]	~293K ảnh độ phân giải cao	Dữ liệu bổ sung cho fine-tune backbone (mô tả chi tiết do chuyên gia biên soạn)

5.2 Phương pháp so sánh (Baselines / SOTA)

Bảng 3 liệt kê các phương pháp đối chiếu, tương ứng trực tiếp với ba thể hệ kỹ thuật đã phân tích ở Mục 3.3, cùng một mốc tham chiếu tối thiểu (CLIP zero-shot) và một mốc truyền thống (BM25) để định vị đóng góp trên toàn phổ công nghệ.

5.3 Ablation Study

Để định lượng đóng góp riêng lẻ của từng thành phần kiến trúc, đề tài thực hiện các biến thể ablation trong Bảng 4.

Bảng 3: Phương pháp so sánh (Baselines / SOTA)

Phương pháp	Loại	Ý nghĩa so sánh
ElasticSearch (BM25)	Keyword-based	Mốc tham chiếu dưới cùng: chứng minh giá trị của biểu diễn ngữ nghĩa liên tục so với khớp từ khóa
CLIP zero-shot [1]	VLM tổng quát, không fine-tune	Chứng minh giá trị của việc fine-tune chuyên ngành (Fashion-CLIP) và của Combiner Network
TIRG [4]	Gating/Residual	Đại diện thể hệ CIR đầu tiên (backbone huấn luyện từ đầu)
CoSMo [5],	Attention tường minh	Đại diện thể hệ CIR thứ hai (modulator/explicit matching, vẫn backbone riêng)
ARTEMIS [6]	CLIP-based	Đối chiếu trực tiếp với phương pháp đề xuất – cùng dùng CLIP backbone nhưng chưa fine-tune miền thời trang
CLIP4Cir [7],	Combiner	
FashionVLP [8]	Fashion-CLIP + Cross-Attention	
FC²AC (đề xuất)		–

Bảng 4: Các biến thể Ablation Study

Biến thể	Mục đích kiểm định
Backbone: CLIP gốc vs. Fashion-CLIP fine-tune	Định lượng đóng góp của G1 (backbone chuyên biệt hóa)
Fusion: TIRG-style gating vs. Cross-Attention	Định lượng đóng góp của G2 (cơ chế fusion)
Combiner (cùng backbone)	
Loss: chỉ $\mathcal{L}_{\text{InfoNCE}}$ vs. $\mathcal{L}_{\text{InfoNCE}} + \lambda \mathcal{L}_{\text{attr}}$	Định lượng đóng góp của G3 (giám sát phụ trợ)
Backbone: đóng băng (frozen) vs. fine-tune toàn bộ trong lúc huấn luyện Combiner	Đánh giá đánh đổi giữa chi phí huấn luyện và độ chính xác

5.4 Đánh giá đo lường (Evaluation Metrics)

- **Chỉ số chính:** Recall@10 và Recall@50, tính trên từng category (Dress, Shirt, Tootie) của FashionIQ và lấy trung bình trên cả ba category – đúng theo protocol đánh giá chính thức của benchmark FashionIQ.
- **Chỉ số bổ sung:** Mean Reciprocal Rank (MRR) trên tập test giữ riêng, và Recall@10/50 trên Fashion-200K để đối chiếu khả năng tổng quát hóa ngoài FashionIQ.
- **Cấu hình huấn luyện dự kiến:** Optimizer AdamW, learning rate warm-up + cosine decay, batch size xác định theo bộ nhớ GPU sẵn có, huấn luyện Combiner Network trong khi backbone có thể đóng băng hoặc fine-tune tùy biến thể ablation (Bảng 4). Toàn bộ thực nghiệm được lặp lại với ít nhất 3 random seed để báo cáo trung bình và độ lệch chuẩn.

6 Rủi ro và Phương án dự phòng

Bảng 5 liệt kê các rủi ro chính – chủ yếu ở mức mô hình và thực nghiệm – cùng phương án dự phòng tương ứng.

Bảng 5: Bảng phân tích rủi ro và phương án dự phòng

Rủi ro	Mức độ	Phương án dự phòng
Không tái lập được (reproduce) đúng số liệu công bố của CLIP4Cir/ARTEMIS do khác biệt hyperparameter/hạ tầng huấn luyện	Cao	Dùng lại mã nguồn công khai (nếu có) và checkpoint tiền huấn luyện làm điểm khởi đầu; chỉ điều chỉnh tối thiểu; báo cáo rõ khoảng cách (gap) nếu không tái lập được hoàn toàn
Fine-tune Fashion-CLIP overfit trên dữ liệu quy mô nhỏ (Fashion-200K/Fashion-Gen)	Cao	Áp dụng Parameter-Efficient Fine-Tuning (LoRA) thay vì full fine-tune; tăng cường data augmentation; theo dõi validation loss sát sao
Nhánh giám sát phụ trợ $\mathcal{L}_{attr}$ gây nhiễu (negative transfer) thay vì cải thiện $\mathcal{L}_{InfoNCE}$	Trung bình	Grid search λ trên tập validation; nếu không cải thiện, báo cáo như một phát hiện thực nghiệm (negative result) kèm phân tích nguyên nhân
Giới hạn tài nguyên GPU khiến không chạy đủ toàn bộ Ablation Study (Bảng 4) trong thời gian TT2	Trung bình	Ưu tiên ablation theo thứ tự $G1 \rightarrow G2 \rightarrow G3$; cắt giảm số random seed lặp lại (từ 3 xuống 1–2) cho các biến thể phụ nếu cần
Nhãn attribute trên FashionIQ không đầy đủ/nhất quán để huấn luyện nhánh phụ trợ	Thấp	Bổ sung nhãn category/attribute mượn từ DeepFashion cho cùng nhóm sản phẩm; loại bỏ mẫu thiếu nhãn khỏi $\mathcal{L}_{attr}$ (vẫn giữ trong $\mathcal{L}_{InfoNCE}$)

7 Dự kiến sản phẩm bàn giao và Ý nghĩa

7.1 Dự kiến sản phẩm bàn giao (Deliverables)

- (1) Checkpoint mô hình Fashion-CLIP đã fine-tune và Cross-Attention Combiner Network đã huấn luyện.
- (2) Mã nguồn nghiên cứu (training & evaluation pipeline) tái lập được, kèm cấu hình các biến thể ablation.
- (3) Báo cáo/bài báo khoa học trình bày kết quả Ablation Study và bảng so sánh Recall@10/50 với các SOTA (TIRG, CoSMo, ARTEMIS, CLIP4Cir, FashionVLP).
- (4) Báo cáo khóa luận đầy đủ, kèm phân tích lỗi định tính (các trường hợp mô hình thất bại và nguyên nhân).

- (5) (Tùy chọn, nếu còn thời gian): một prototype minh họa nhỏ dùng FAISS/HNSW để demo truy vấn trực tiếp trên một catalog mẫu (xem Mục 8.3).

7.2 Ý nghĩa khoa học và thực tiễn

- **Về mặt khoa học:** Đề tài định lượng rõ ràng đóng góp của backbone chuyên biệt hóa theo miền (Fashion-CLIP), cơ chế fusion (Cross-Attention so với gating), và tín hiệu giám sát phụ trợ (attribute-level) đối với bài toán Composed Image Retrieval – ba trục mà các công trình hiện có (Bảng 1) mới chỉ giải quyết riêng lẻ.
- **Về mặt thực tiễn:** Mô hình được huấn luyện là thành phần cốt lõi có thể tái sử dụng cho các sản phẩm TMDT ngành thời trang muốn cải thiện tỷ lệ tìm thấy sản phẩm (search success rate) khi tích hợp tìm kiếm bằng ảnh kết hợp văn bản.

7.3 Hướng mở rộng ứng dụng (ngoài phạm vi đánh giá chính)

Nếu mô hình đề xuất đạt kết quả khả quan, một hướng mở rộng tự nhiên là đóng gói f_c thành truy vấn cho một chỉ mục Approximate Nearest Neighbor quy mô lớn, sử dụng thuật toán FAISS [14] hoặc HNSW [15] – vốn là các thuật toán chỉ mục ANN nền tảng cho hầu hết Vector Database thương mại hiện nay (Milvus, Qdrant). Việc thiết kế đầy đủ một hệ thống Backend production (API Gateway, đồng bộ dữ liệu real-time với CSDL quan hệ, đảm bảo SLA về độ trễ/thông lượng) nằm ngoài phạm vi của đề tài này và có thể là chủ đề của một đề tài kỹ thuật hệ thống riêng biệt.

8 Tài liệu tham khảo

References

- [1] Radford, A., Kim, J.W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., Sastry, G., Askell, A., Mishkin, P., Clark, J., Krueger, G., & Sutskever, I. (2021). Learning transferable visual models from natural language supervision. *Proceedings of the 38th International Conference on Machine Learning (ICML)*.
- [2] Chia, P.J., Attanasio, G., Bianchi, F., Terragni, S., Magalhães, A.R., Goncalves, D., Greco, C., & Tagliabue, J. (2022). Fashion-CLIP: Enhancing e-commerce product retrieval with vision-language models. *Scientific Reports*, 12(1), 1–15.
- [3] Zhuge, M., Gao, D., Fan, D.P., Jin, L., Chen, B., Zhou, H., Qiu, M., & Shao, L. (2021). Kaleido-BERT: Vision-language pre-training on fashion domain. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*.
- [4] Vo, N., Jiang, L., Sun, C., Murphy, K., Li, L.-J., Fei-Fei, L., & Hays, J. (2019). Composing text and image for image retrieval – an empirical odyssey. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*.
- [5] Lee, S., Kim, D., & Han, B. (2021). CoSMo: Content-style modulation for image retrieval with text feedback. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 802–812.

- [6] Delmas, G., Rezende, R.S., Csúrká, G., & Larlus, D. (2022). ARTEMIS: Attention-based retrieval with text-explicit matching and implicit similarity. *Proceedings of the International Conference on Learning Representations (ICLR)*.
- [7] Baldrati, A., Bertini, M., Uricchio, T., & Del Bimbo, A. (2022). Effective conditioned and composed image retrieval combining CLIP-based features. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 21466–21474.
- [8] Goenka, S., Zheng, Z., Jaiswal, A., Chada, R., Wu, Y., Hedau, V., & Natarajan, P. (2022). FashionVLP: Vision language transformer for fashion retrieval with feedback. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 14105–14115.
- [9] Wu, H., Gao, Y., Guo, X., Al-Halah, Z., Rennie, S., Grauman, K., & Feris, R. (2021). Fashion IQ: A new dataset towards retrieving images by natural language feedback. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*.
- [10] Liu, Z., Luo, P., Qiu, S., Wang, X., & Tang, X. (2016). DeepFashion: Powering robust clothes recognition and retrieval with rich annotations. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 1096–1104.
- [11] Ge, Y., Zhang, R., Wang, X., Tang, X., & Luo, P. (2019). DeepFashion2: A versatile benchmark for detection, pose estimation, segmentation and re-identification of clothing images. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 5337–5345.
- [12] Han, X., Wu, Z., Huang, P.X., Zhang, X., Zhu, M., Li, Y., Zhao, Y., & Davis, L.S. (2017). Automatic spatially-aware fashion concept discovery. *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 1472–1480.
- [13] Rostamzadeh, N., Hosseini, S., Boquet, T., Stokowiec, W., Zhang, Y., Jauvin, C., & Pal, C. (2018). Fashion-Gen: The generative fashion dataset and challenge. *arXiv preprint arXiv:1806.08317*.
- [14] Johnson, J., Douze, M., & Jégou, H. (2019). Billion-scale similarity search with GPUs. *IEEE Transactions on Big Data*, 7(3), 535–547.
- [15] Malkov, Y.A., & Yashunin, D.A. (2020). Efficient and robust approximate nearest neighbor search using hierarchical navigable small world graphs. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 42(4), 824–836.