

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



THỰC TẬP 1 + 2

Đề cương nghiên cứu tổng quan

**Nghiên cứu truy xuất sản phẩm thời trang đa
phương thức có điều kiện ở mức sản phẩm với dữ
liệu đa góc nhìn (Multi-View CIR)**

Giảng viên: PGS.TS. Võ Thị Ngọc Châu
Học viên: Võ Thị Bích Phượng - 2470570

TP. HỒ CHÍ MINH, THÁNG 9/2026



Mục lục

1	Bối cảnh và Đặt vấn đề	2
1.1	Hạn chế cốt lõi: giả định một ảnh tham khảo duy nhất	2
1.2	Bài toán Multi-View CIR và công trình nền tảng	2
1.3	Vì sao chọn hướng này	2
2	Mục tiêu và Phạm vi nghiên cứu	3
2.1	Mục tiêu tổng quát	3
2.2	Mục tiêu cụ thể	3
2.3	Phạm vi nghiên cứu	3
3	Tổng quan tình hình nghiên cứu (Literature Review)	4
3.1	Các thể hệ phương pháp CIR	4
3.2	Biểu diễn thị giác-ngôn ngữ trong miền thời trang	4
3.3	Các bộ dữ liệu CIR	4
3.4	Bảng tổng hợp Literature Review	5
4	Khoảng trống nghiên cứu và Phương pháp đề xuất	6
4.1	Phân tích công trình nền tảng ProCIR	6
4.2	Khoảng trống nghiên cứu (Research Gap)	6
4.3	Phương pháp đề xuất: MV-SHN	7
4.3.1	Bước 0 – Chẩn đoán cơ chế chọn góc nhìn ngầm (kiểm định G1)	7
4.3.2	Đóng góp 1 – View-Aware Selection (giải quyết G1)	7
4.3.3	Đóng góp 2 – Hard Negative Mining có lọc mẫu âm giả (giải quyết G5)	8
4.3.4	Cải tiến phụ – View-dropout khi huấn luyện (hỗ trợ G2)	8
5	Dữ liệu và Kế hoạch thực nghiệm	9
5.1	Dữ liệu	9
5.2	Phương pháp so sánh	10
5.3	Ablation Study	10
5.4	Đánh giá đo lường	11
5.5	Cấu hình thực nghiệm trên tài nguyên hạn chế	11
5.6	Ngân sách tính toán	12
6	Kế hoạch thực hiện	13
7	Rủi ro và Phương án dự phòng	14
8	Dự kiến sản phẩm bàn giao và Ý nghĩa	15
8.1	Sản phẩm bàn giao	15
8.2	Ý nghĩa khoa học và thực tiễn	15
8.3	Hướng mở rộng ứng dụng (ngoài phạm vi đánh giá chính)	15
9	Tài liệu tham khảo	15

1 Bối cảnh và Đặt vấn đề

Trong Thương mại điện tử (TMĐT) ngành hàng dệt may và thời trang, người dùng cuối, chẳng hạn đối tác mua sỉ (B2B buyers/merchandisers), có xu hướng tìm kiếm sản phẩm bằng cách kết hợp một hình ảnh tham khảo với một đoạn văn bản điều chỉnh (*modifier text*), ví dụ: “tìm mẫu áo giống ảnh này nhưng đổi sang khoá kéo lộ ở lưng và thêm túi ngực”. Đây là bài toán **Composed Image Retrieval (CIR)**: truy xuất ảnh đích dựa trên cặp truy vấn (ảnh, văn bản).

1.1 Hạn chế cốt lõi: giả định một ảnh tham khảo duy nhất

Toàn bộ dòng nghiên cứu CIR, từ TIRG (2019) tới các mô hình dựa trên MLLM năm 2025–2026, đều mặc định truy vấn chỉ gồm **một ảnh tham khảo**. Yuan et al. [1] gọi đây là hiện tượng **View Incompleteness** (khuyết góc nhìn) và chỉ ra rằng nó mâu thuẫn với thực tế TMĐT: sản phẩm thời trang được trưng bày từ nhiều góc (trước, sau, nghiêng, cận cảnh), và người mua suy luận trên toàn bộ tập ảnh đó chứ không phải một ảnh đơn lẻ.

Ví dụ điển hình: một chiếc đầm có cổ chữ V sâu chỉ quan sát được ở góc chụp trước, trong khi dây đan chéo hở lưng chỉ quan sát được ở góc chụp sau. Không một ảnh đơn nào đồng thời chứa hai đặc trưng định danh này. Khi văn bản điều chỉnh đề cập tới vùng không quan sát được (ví dụ yêu cầu “thiết kế hở lưng” trong khi chỉ có ảnh mặt trước), kết quả truy xuất thiếu căn cứ về mặt bản chất.

Về mặt định lượng, từ quy mô công bố của FashionMV (127K sản phẩm, 472K ảnh – xem Bảng 4), số ảnh trung bình mỗi sản phẩm khoảng $472K/127K \approx 3.7$. Đây là số trung bình suy ra từ số liệu tổng, không phải phân bố chi tiết. Tỷ lệ sản phẩm chỉ có 1–2 ảnh sẽ được thống kê trực tiếp trên tập dữ liệu ở Tháng 1 (Bảng 9) và báo cáo ở báo cáo giữa kỳ TT1; con số này là cơ sở thực nghiệm cho khoảng trống G2 (Mục 4.2).

1.2 Bài toán Multi-View CIR và công trình nền tảng

Yuan et al. [1] định nghĩa hình thức bài toán **Multi-View CIR**, tổng quát hoá CIR từ mức ảnh lên mức sản phẩm: mỗi sản phẩm P được biểu diễn bởi tập ảnh đa góc $\mathcal{V}^P = \{I_1^P, \dots, I_{N_P}^P\}$, được tổng hợp thành một embedding duy nhất; công thức suy biến về CIR chuẩn khi $N_P = 1$. Kèm theo đó, nhóm tác giả công bố:

- **FashionMV** – bộ dữ liệu đa góc nhìn quy mô lớn đầu tiên cho CIR mức sản phẩm: 127K sản phẩm, 472K ảnh, hơn 220K triplet, xây dựng tự động qua ba giai đoạn dùng các mô hình đa phương thức lớn.
- **ProCIR** – khung mô hình trên nền MLLM (Qwen3.5-0.8B) với ba cơ chế: đối thoại hai giai đoạn (MT), căn chỉnh dựa trên caption (Align), dẫn dắt chuỗi suy luận (CoT), cùng bước tinh chỉnh có giám sát (SFT) tùy chọn.

Kết quả tốt nhất của ProCIR vượt mọi baseline, kể cả mô hình nhúng đa phương thức lớn gấp 10 lần tham số. Dữ liệu, mã nguồn và trọng số đều đã công khai, tạo nền tảng thuận lợi để đề tài kế thừa và mở rộng.

1.3 Vì sao chọn hướng này

- (i) Bài toán vừa được định nghĩa (tháng 4/2026). Theo khảo sát của đề tài **tính đến tháng 9/2026** (nguồn: arXiv, Google Scholar, kỷ yếu CVPR, ICCV, ECCV, ACM MM 2025–2026; từ khoá: *multi-view composed image retrieval*, *product-level composed retrieval*, *multi-image reference CIR*), FashionMV/ProCIR là công trình duy nhất đặt bài toán ở mức sản phẩm đa góc nhìn. Các công trình CIR thời trang cùng thời điểm như FIRE-CIR [21] vẫn giữ giả định một ảnh tham khảo. Khảo sát sẽ được cập nhật trước báo cáo giữa kỳ.

- (ii) Dữ liệu và mã nguồn công khai, giảm mạnh rủi ro tái lập.
- (iii) Bối cảnh đa góc nhìn khớp trực tiếp với nhu cầu tra cứu sản phẩm theo mã hàng của B2B buyers nêu ở đầu mục này.

2 Mục tiêu và Phạm vi nghiên cứu

2.1 Mục tiêu tổng quát

Nghiên cứu thực nghiệm và mở rộng có hệ thống phương pháp truy xuất sản phẩm thời trang đa phương thức ở mức sản phẩm (Multi-View CIR), tập trung vào hai điểm yếu phương pháp của công trình nền tảng: (i) chưa có cơ chế lựa chọn góc nhìn **tường minh** theo ngữ nghĩa văn bản điều chỉnh, và cơ chế ngầm hiện có chưa được kiểm chứng; (ii) chưa khai thác mẫu âm khó (hard negative) vốn có sẵn trong quy trình xây dựng dữ liệu. Đồng thời, đề tài bổ sung hai đánh giá mà công trình gốc chưa thực hiện: độ bền theo số lượng góc nhìn và khả năng chuyển giao sang benchmark do người gán nhãn.

2.2 Mục tiêu cụ thể

- (a) Khảo sát và phân loại các hướng tiếp cận CIR, xác định vị trí của Multi-View CIR trong bức tranh chung.
- (b) Tái lập (reproduce) một cấu hình tham chiếu của ProCIR trên tài nguyên hạn chế làm mốc so sánh; mọi biến thể khởi tạo từ cùng một checkpoint và cùng quy trình huấn luyện.
- (c) **Chẩn đoán** cơ chế lựa chọn góc nhìn ngầm của ProCIR: đo mức độ chú ý từ văn bản điều chỉnh tới từng góc nhìn và so với góc nhìn mà văn bản đề cập.
- (d) Đề xuất và hiện thực module lựa chọn góc nhìn tường minh có điều kiện trên văn bản điều chỉnh (View-Aware Selection).
- (e) Đề xuất chiến lược khai thác mẫu âm khó từ các ứng viên bị loại trong quy trình dựng FashionMV, kèm cơ chế lọc mẫu âm giả (false negative).
- (f) Xây dựng bộ đánh giá độ bền theo số lượng góc nhìn (view-dropout khi suy luận) và thử nghiệm view-dropout khi huấn luyện như một biện pháp tăng độ bền.
- (g) Đánh giá khả năng chuyển giao sang FashionIQ (benchmark do người gán nhãn) nhằm định lượng độ lệch của dữ liệu sinh bởi mô hình.
- (h) Đặt kết quả FashionIQ vào bối cảnh bằng cách **chạy lại trong cùng hạ tầng** hai mốc tham chiếu CLIP zero-shot và CLIP4Cir (Recall@10, Recall@50). Số liệu công bố của TIRG, CoSMo, ARTEMIS, FashionVLP chỉ được trình bày để tham khảo bối cảnh, **không dùng để rút kết luận** (xem nguyên tắc ở Mục 5.5).

2.3 Phạm vi nghiên cứu

- **Trong phạm vi:** Thiết kế module mô hình, hàm mất mát, quy trình huấn luyện và ablation; đánh giá học thuật trên FashionMV và FashionIQ.
- **Ngoài phạm vi:** Xây dựng lại dataset từ đầu (kể thừa FashionMV đã công bố); khắc phục lỗi dữ liệu nền G4 (chỉ ghi nhận, xem Mục 4.2); triển khai hệ thống Backend production; huấn luyện MLLM nền tảng từ đầu. Đề tài chỉ tinh chỉnh trên mô hình đã huấn luyện trước.

- **Ràng buộc tài nguyên:** Toàn bộ thực nghiệm chạy trên **một GPU đơn (24GB VRAM)** thay vì cụm 10 GPU như công trình gốc. Ràng buộc này định hình các lựa chọn kỹ thuật và ngân sách tính toán ở Mục 5.5–5.6.
- **Định vị đóng góp:** Từng kỹ thuật thành phần (attention pooling có điều kiện, khai thác mẫu âm khó) đã phổ biến ở các bài toán truy xuất khác. Đóng góp của đề tài nằm ở việc chẩn đoán, điều chỉnh và kiểm chứng chúng cho bài toán Multi-View CIR vừa được định nghĩa, cùng hai đánh giá độc lập G2, G3.

3 Tổng quan tình hình nghiên cứu (Literature Review)

3.1 Các thể hệ phương pháp CIR

(i) **Hợp nhất đặc trưng có giám sát.** Vo et al. [2] đề xuất TIRG với cổng phần dư (residual gating) hợp nhất vector ảnh và vector văn bản điều chỉnh. Các công trình kế tiếp cải tiến cơ chế hợp nhất bằng điều biến nội dung–phong cách [3] hoặc attention tường minh [4].

(ii) **Combiner trên nền CLIP.** CLIP [5] đưa lĩnh vực sang không gian nhúng được căn chỉnh sẵn. Baldrati et al. [6] (CLIP4Cir) xây một Combiner Network nhỏ trên đặc trưng CLIP và trở thành baseline được dùng rộng rãi. Trong miền thời trang, FashionVLP [7] khai thác thông tin thị giác đa mức ngữ cảnh từ một ảnh.

(iii) **Zero-shot CIR.** Nhằm tránh chi phí gán nhãn triplet, Pic2Word [10] và SEARLE [11] ánh xạ ảnh thành pseudo-word token trong không gian embedding của CLIP; LinCIR [12] huấn luyện chỉ bằng dữ liệu văn bản qua self-masking projection.

(iv) **CIR dựa trên LLM/MLLM và suy luận mịn.** CoLLM [13] dùng LLM làm backbone sinh embedding cho ảnh và văn bản, đánh dấu bước chuyển từ backbone CLIP sang MLLM. FineCIR [22] phân tích tường minh ngữ nghĩa điều chỉnh mịn trong văn bản. FIRE-CIR [21] (CVPR 2026) phân rã văn bản điều chỉnh thành các câu hỏi thị giác theo thuộc tính và kiểm chứng bằng chứng thị giác trên ảnh tham khảo và ảnh ứng viên, chủ yếu dùng cho bước xếp hạng lại. Cả hai đều hướng tới việc “văn bản chỉ vào đâu trên ảnh” – cùng tinh thần với module lựa chọn góc nhìn của đề tài – nhưng vẫn thao tác trên một ảnh tham khảo.

(v) **Mở rộng phạm vi bài toán.** Các hướng gần đây mở rộng CIR sang ngữ nghĩa mịn, tương tác đa lượt và miền video. Yuan et al. [1] mở rộng theo một trục khác: phía đầu vào thị giác, từ một ảnh lên tập ảnh đa góc của một sản phẩm.

3.2 Biểu diễn thị giác–ngôn ngữ trong miền thời trang

Dữ liệu thời trang chứa các thuộc tính mịn (chất liệu, kiểu cắt, phom dáng), đặt yêu cầu cao lên biểu diễn đa phương thức. Fashion-CLIP [8] tinh chỉnh CLIP trên dữ liệu TMDT thời trang. Về phía đa góc nhìn, FashionViL [9] nhận ra rằng dữ liệu TMDT gắn nhiều ảnh với một mô tả và đề xuất Multi-View Contrastive Learning; tuy nhiên cơ chế này chỉ khuyến khích tính nhất quán ngữ nghĩa giữa từng ảnh, còn khi truy xuất vẫn thao tác trên từng ảnh riêng lẻ. Nói cách khác, các phương pháp hiện có coi ảnh đa góc như một dạng tăng cường dữ liệu cho mô hình đơn ảnh, chứ không tổng hợp thành một biểu diễn ở mức sản phẩm.

3.3 Các bộ dữ liệu CIR

FashionIQ [14] thu thập mô tả tương đối từ người gán nhãn và là benchmark CIR thời trang phổ biến nhất. FACap [15] dựng hơn 227K triplet thời trang mịn bằng quy trình tự động VLM+LLM. Điểm chung: đều tuân theo mô hình một góc nhìn, mỗi triplet định nghĩa ở mức ảnh. Đáng chú ý, FACap lấy nguồn từ Fashion200K và DeepFashion-MultiModal (đều có nhiều ảnh mỗi sản phẩm) nhưng chủ động loại bỏ các

cặp cùng sản phẩm, làm mất cấu trúc đa góc nhìn. FashionMV [1] là bộ dữ liệu đầu tiên gắn kết ảnh đa góc thành nhóm ở mức sản phẩm.

Bảng 1 tổng hợp đặc điểm đa góc nhìn của ba tập dữ liệu nguồn mà pipeline FashionMV kế thừa. Sự không đồng đều giữa ba nguồn – đặc biệt là tỉ lệ sản phẩm thiếu góc nhìn – là một phần cơ sở cho khoảng trống G2.

Bảng 1: Ba tập dữ liệu nguồn cấu thành FashionMV

Dataset	Đặc điểm	Ghi chú đa góc nhìn
DeepFashion [16]	~800K ảnh, gắn nhãn phong phú (category, attribute, landmark)	Nhiều ảnh/mục nhưng không đảm bảo phủ đủ các góc chuẩn hoá (trước/sau/nghiêng)
Fashion200K [17]	~200K ảnh sản phẩm thương mại kèm mô tả ngắn	Chủ yếu ảnh đơn góc; chỉ một phần mục có ảnh phụ
Fashion-Gen [18]	~293K ảnh độ phân giải cao, mô tả chi tiết do chuyên gia biên soạn	Có ảnh đa góc cho một phần sản phẩm, phân bố không đồng đều giữa các mục

3.4 Bảng tổng hợp Literature Review

Bảng 2: Tổng hợp các hướng tiếp cận CIR và giới hạn đối với bài toán đề tài

Nhóm	Công trình	Giới hạn đối với Multi-View CIR
Hợp nhất có giám sát	TIRG [2], CoSMo [3], ARTEMIS [4]	Không dựa trên mô hình thị giác-ngôn ngữ đã căn chỉnh sẵn; chỉ nhận một ảnh tham khảo
Combiner trên CLIP	CLIP4Cir [6], FashionVLP [7], Fashion-CLIP [8]	Kiến trúc gắn chặt với truy vấn đơn ảnh; chỉ hỗ trợ tổng hợp hậu kỳ (MeanPool/MaxSim)
Zero-shot CIR	Pic2Word [10], SEARLE [11], LinCIR [12]	Ánh xạ một ảnh thành một pseudo-word token; không có khái niệm sản phẩm
CIR dựa trên MLLM / suy luận mịn	CoLLM [13], FineCIR [22], FIRE-CIR [21]	Vẫn ở mức ảnh; định vị vùng điều chỉnh trong <i>một</i> ảnh, chưa xử lý lựa chọn giữa nhiều góc nhìn
Đa góc nhìn trong thời trang	FashionViL [9]	Dùng đa góc như tăng cường dữ liệu; truy xuất vẫn ở mức ảnh
Multi-View CIR	FashionMV / ProCIR [1]	Công trình duy nhất hiện có (tính đến 09/2026); các khoảng trống được phân tích ở Mục 4.2

4 Khoảng trống nghiên cứu và Phương pháp đề xuất

4.1 Phân tích công trình nền tảng ProCIR

ProCIR [1] dùng Qwen3.5-0.8B làm backbone, thêm token đặc biệt `<emb>` mà trạng thái ẩn tại vị trí đó đóng vai trò embedding mức sản phẩm. Toàn bộ ảnh đa góc được đưa vào như visual token trong một lượt; causal self-attention tổng hợp thông tin xuyên góc nhìn mà không cần pooling tường minh. Đối thoại hai giai đoạn tách Turn 1 (nhận thức – chỉ ảnh) và Turn 2 (suy luận – thêm văn bản điều chỉnh); theo nhóm tác giả, Turn 1 tạo ra một embedding thuần thị giác, điều kiện cần để căn chỉnh ảnh–văn bản phía nguồn. Hàm mất mát tổng:

$$\mathcal{L} = \mathcal{L}_{\text{cir}} + \lambda_d \mathcal{L}_{\text{doc}} + \lambda_s \mathcal{L}_{\text{src}}, \quad \lambda_d = \lambda_s = 0,25,$$

trong đó cả ba thành phần dựa trên SymInfoNCE với nhiệt độ $\tau = 0,07$, mẫu âm lấy từ các mẫu còn lại trong cùng batch.

Ablation của nhóm tác giả trên 16 cấu hình (8 biến thể $\times$ 2 cách khởi tạo) cho thấy: căn chỉnh (Align) là cơ chế quan trọng nhất; đối thoại hai giai đoạn (MT) là điều kiện tiên quyết để Align phát huy; SFT và CoT là hai đường bơm tri thức dư thừa một phần – khi mô hình đã qua SFT thì lợi ích biên của CoT giảm.

4.2 Khoảng trống nghiên cứu (Research Gap)

Bảng 3: Năm khoảng trống nghiên cứu và bằng chứng

Mã	Khoảng trống	Bằng chứng / Lập luận
G1	Chưa có cơ chế lựa chọn góc nhìn tường minh ; cơ chế ngầm chưa được kiểm chứng	Trong ProCIR, text token của Turn 2 attend được tới visual token nên việc chọn góc nhìn theo văn bản <i>có thể</i> đã diễn ra ngầm. Tuy nhiên chưa có phân tích nào cho thấy attention có dồn vào đúng góc nhìn văn bản đề cập. Văn bản điều chỉnh thường chỉ đích danh 1–2 góc; 81,6% triplet chỉ liên quan tổ hợp trước+sau. Với dữ liệu huấn luyện thu gọn, một inductive bias tường minh có thể có lợi – giả thuyết này được kiểm định bằng thí nghiệm chẩn đoán (Mục 4.3.1) <i>trước</i> khi xây module.
G2	Chưa đánh giá độ bền khi thiếu góc nhìn	Công thức suy biến về CIR chuẩn khi $N_P = 1$, nhưng không có thực nghiệm theo số lượng góc nhìn. FashionMV có trung bình $\approx 3,7$ ảnh/sản phẩm; tỉ lệ sản phẩm chỉ 1–2 ảnh sẽ được thống kê ở Tháng 1.
G3	Chưa kiểm chứng chéo trên benchmark do người gán nhãn	Toàn bộ FashionMV do mô hình sinh, đánh giá cũng chỉ trên tập validation của chính nó; không có số liệu trên FashionIQ.
G4	Chất lượng dữ liệu còn hạn chế	Bộ lọc ảo giác hướng trái/phải chỉ đạt precision 42,9% và recall 36,0%; đánh giá thủ công cho thấy 6,2% sản phẩm có ảo giác nghiêm trọng, trong đó lỗi trái–phải chiếm hơn 80%.
G5	Bỏ phí mẫu âm khó có sẵn	Giai đoạn 3 của pipeline đưa 10 ứng viên cùng danh mục, cùng giới tính cho mô hình chọn <i>tối đa 2</i> target. Các ứng viên bị loại là nguồn mẫu âm khó tiềm năng nhưng bị bỏ đi; huấn luyện chỉ dùng in-batch negative. Lưu ý: do giới hạn “tối đa 2”, ứng viên bị loại <i>không chắc chắn</i> sai – cần lọc mẫu âm giả (Mục 4.3.3).

Phạm vi giải quyết. Đề tài giải quyết G1 và G5 bằng đóng góp phương pháp; G2 và G3 bằng đóng góp đánh giá (G2 kèm thử nghiệm view-dropout khi huấn luyện); G4 chỉ được ghi nhận như giới hạn của dữ liệu nền và khảo sát định tính trên mẫu nhỏ.

4.3 Phương pháp đề xuất: MV-SHN

Đề tài đề xuất **MV-SHN** (*Multi-View Selection with Hard Negatives*), gồm một bước chẩn đoán và hai đóng góp phương pháp trên nền ProCIR, minh hoạ ở Hình 1.

4.3.1 Bước 0 – Chẩn đoán cơ chế chọn góc nhìn ngầm (kiểm định G1)

Nhân góc nhìn. Với mỗi ảnh nguồn, xác định loại góc $c(I_i) \in \{\text{front, back, side, detail}\}$: ưu tiên metadata của FashionMV (nếu có); nếu không, dùng phân loại zero-shot bằng CLIP với prompt mô tả góc chụp, kiểm định trên 200 ảnh gán nhãn thủ công (yêu cầu độ chính xác $\geq 85\%$). Với mỗi văn bản điều chỉnh T , gán góc mục tiêu $\hat{y}(T)$ bằng luật từ khoá (ví dụ *back, open back, zipper at back* $\rightarrow$ back; *neckline, collar, front pocket* $\rightarrow$ front); triplet không khớp luật nào bị loại khỏi tập chẩn đoán.

Phân bố chú ý của baseline. Gọi Ω_i là tập vị trí visual token của góc nhìn i và $\mathcal{T}$ là tập vị trí text token của Turn 2. Mức chú ý của văn bản vào góc nhìn i , với $a_{p,k}$ là trọng số attention từ vị trí p tới vị trí k , lấy trung bình trên K tầng cuối và mọi head:

$$A_i = \frac{\sum_{p \in \mathcal{T}} \sum_{k \in \Omega_i} a_{p,k}}{\sum_{j=1}^{N_P} \sum_{p \in \mathcal{T}} \sum_{k \in \Omega_j} a_{p,k}}.$$

Chỉ số View Hit Rate (VHR):

$$\text{VHR} = \Pr [c(I_{\arg \max_i w_i}) = \hat{y}(T)],$$

với $w_i = A_i$ cho baseline và $w_i = \alpha_i$ cho module đề xuất. Mốc ngẫu nhiên là $1/N_P$ trên mỗi truy vấn.

Quy tắc quyết định (định trước): nếu $\text{VHR}_{\text{baseline}} \geq 0,8$, cơ chế ngầm đã chọn đúng góc nhìn; khi đó G1 được định vị lại theo hướng khả năng diễn giải và giám sát yếu (G5 vẫn là ưu tiên số một). Ngược lại, kết quả là bằng chứng trực tiếp cho G1.

4.3.2 Đóng góp 1 – View-Aware Selection (giải quyết G1)

Biểu diễn từng góc nhìn v_i . Mỗi ảnh I_i được mã hoá *độc lập* qua vision encoder của backbone (ViT + khối merger chiếu sang không gian ẩn của LLM, kích thước d), thu được $Z_i \in \mathbb{R}^{L_i \times d}$. Lấy $v_i = \frac{1}{L_i} \sum_l Z_i[l] \in \mathbb{R}^d$. Vì v_i tính *trước* LLM, nó không bị rò rỉ thông tin giữa các góc nhìn do causal attention.

Biểu diễn văn bản t . Văn bản điều chỉnh T được đưa qua LLM (dùng chung trọng số và LoRA) trong một lượt chỉ-văn-bản; $t \in \mathbb{R}^d$ là trung bình trạng thái ẩn tầng cuối trên các text token. Chi phí thấp vì văn bản ngắn.

Trọng số và biểu diễn có điều kiện:

$$\alpha_i = \frac{\exp(\phi(v_i)^\top \psi(t)/\sqrt{d_k})}{\sum_{j=1}^{N_P} \exp(\phi(v_j)^\top \psi(t)/\sqrt{d_k})}, \quad \bar{s} = \sum_{i=1}^{N_P} \alpha_i v_i,$$

với $\phi, \psi : \mathbb{R}^d \rightarrow \mathbb{R}^{d_k}$ là hai phép chiếu tuyến tính học được.

Kết nối phần dư khởi tạo bằng 0. Gọi $h_{\langle \text{emb} \rangle}$ là embedding truy vấn của ProCIR (trạng thái ẩn tại $\langle \text{emb} \rangle$ sau Turn 2). Embedding truy vấn cuối cùng:

$$q = h_{\langle \text{emb} \rangle} + g \cdot W_o \bar{s}, \quad g \in \mathbb{R}, g_{\text{init}} = 0,$$

với $W_o \in \mathbb{R}^{d \times d}$ khởi tạo ngẫu nhiên nhỏ (để gradient vẫn lan tới g ngay từ bước đầu). Tại thời điểm khởi tạo q trùng khớp ProCIR, nên module không thể phá vỡ biểu diễn đã học ở bước đầu (cùng nguyên lý cố định khởi tạo 0 trong LLaMA-Adapter [30]). Tổng tham số thêm vào khoảng $2dd_k + d^2$, không đáng kể so với backbone.

Phía đích. Embedding sản phẩm đích e tính đúng như ProCIR, không qua module. Lý do: sản phẩm đích không có văn bản điều chỉnh, và biểu diễn đích cần *độc lập với truy vấn* để có thể lập chỉ mục trước (điều kiện cho hướng mở rộng ANN ở Mục 8.3). Việc lựa chọn góc nhìn được hiểu là mã hoá *ý định* của truy vấn.

Trường hợp suy biến. Khi $N_P = 1$: $\alpha_1 = 1$, $\bar{s} = v_1$, module suy biến thành một phép bổ sung đặc trưng toàn cục của ảnh duy nhất.

Biến thể giám sát yếu (tùy chọn). Trên các triplet có nhãn $\hat{y}(T)$, thêm $\mathcal{L}_{\text{view}} = -\log \sum_{i: c(I_i)=\hat{y}(T)} \alpha_i$ với trọng số λ_v nhỏ, được đánh giá riêng trong ablation.

Giả thuyết kiểm định: (H1) $\text{VHR}_{\text{VAS}} > \text{VHR}_{\text{baseline}}$; (H2) $\Delta \text{R@10} > 0$ với khoảng tin cậy bootstrap 95% không chứa 0, đặc biệt trên tập con triplet có văn bản đề cập góc sau.

4.3.3 Đóng góp 2 – Hard Negative Mining có lọc mẫu âm giả (giải quyết G5)

Quy trình dựng FashionMV chọn target từ nhóm 10 ứng viên cùng danh mục, cùng giới tính. Các ứng viên không được chọn là nguồn mẫu âm khó: giống về danh mục, khác về chi tiết cấu tạo. Mẫu âm khó đã được chứng minh cải thiện chất lượng biểu diễn trong học tương phản [25]. Hàm mất mát mở rộng:

$$\mathcal{L}_{\text{cir}}^{\text{HN}} = -\log \frac{\exp(q^\top e^+ / \tau)}{\exp(q^\top e^+ / \tau) + \sum_{k \in \mathcal{B}} \exp(q^\top e_k^- / \tau) + \sum_{m \in \mathcal{H}} \exp(q^\top e_m^- / \tau)},$$

trong đó e^+ là embedding sản phẩm đích, e_k^- và e_m^- là embedding các mẫu âm, $\mathcal{B}$ là tập mẫu âm trong batch và $\mathcal{H}$ là tập mẫu âm khó (sau lọc) của truy vấn.

Lọc mẫu âm giả. Vì mô hình dựng dữ liệu chỉ được chọn tối đa 2 target, một số ứng viên bị loại có thể vẫn thoả văn bản điều chỉnh. Đề tài áp dụng hai tầng lọc:

- (F1) **Lọc theo điểm dương** (theo tinh thần NV-Retriever [27]): dùng baseline tái lập, giữ ứng viên m chỉ khi $s(q, e_m) < \rho \cdot s(q, e^+)$, với $\rho = 0,95$.
- (F2) **Lọc gần trùng lặp:** loại ứng viên có độ tương đồng caption với caption của target $\geq \tau_c$ (chọn τ_c trên tập dev).


Biến thể “không lọc” được đưa vào ablation để định lượng tác động của mẫu âm giả. Hướng thay thế nếu lọc cứng loại quá nhiều ứng viên là debiased contrastive loss [26].

Batch contrastive lớn trên 1 GPU: GradCache. Với InfoNCE, số mẫu âm do *số mẫu cùng tham gia một ma trận similarity* quyết định; gradient accumulation *không* làm tăng con số này. Đề tài dùng GradCache [23]: (1) tính embedding của toàn bộ q , e^+ , $e_{\mathcal{H}}^-$ theo từng chunk ở chế độ không gradient; (2) tính loss và gradient theo embedding trên toàn batch; (3) chạy lại từng chunk có gradient và lan truyền ngược gradient đã lưu. Đỉnh bộ nhớ chỉ phụ thuộc kích thước chunk, nhờ đó batch contrastive $B = 64$ khả thi trên 24GB; cái giá là thời gian tính toán (Mục 5.6). Hàng đợi embedding kiểu MoCo [24] là phương án dự phòng.

Trong bối cảnh này, mẫu âm khó đóng vai trò hỗ trợ cho GradCache: $B = 64$ vẫn nhỏ hơn batch 160 của công trình gốc, và mẫu âm khó cung cấp tín hiệu phân biệt mịn mà in-batch negative ngẫu nhiên không có.

4.3.4 Cải tiến phụ – View-dropout khi huấn luyện (hỗ trợ G2)

Trong huấn luyện, với xác suất p_{vd} , giữ ngẫu nhiên $k \sim \mathcal{U}\{1, \dots, N_P\}$ góc nhìn của sản phẩm nguồn. Biện pháp này gần như không tốn chi phí (còn giảm số visual token) và biến G2 từ một phép đánh giá thành một đóng góp có kiểm chứng.



Hình 1: Kiến trúc MV-SHN. Khối nền xanh kế thừa ProCIR (đối thoại hai giai đoạn, căn chỉnh caption); khối viền cam là đóng góp của đề tài: module lựa chọn góc nhìn với biểu diễn từng góc v_i tính độc lập trước LLM và kết nối phần dư khởi tạo bằng 0; nhánh mẫu âm khó có lọc mẫu âm giả, huấn luyện bằng GradCache. Phía đích không qua module để biểu diễn đích độc lập với truy vấn.

5 Dữ liệu và Kế hoạch thực nghiệm

5.1 Dữ liệu

Bảng 4: Bộ dữ liệu sử dụng

Dataset	Quy mô	Vai trò trong đề tài
FashionMV [1]	127K sản phẩm, 472K ảnh, 220K+ triplet	Dataset chính: huấn luyện và đánh giá Multi-View CIR trên ba tập con DeepFashion, Fashion200K, Fashion-Gen
FashionIQ [14]	77.684 ảnh, 30.134 triplet	Đánh giá chuyển giao (G3): benchmark do người gán nhãn, định lượng độ lệch của dữ liệu sinh bởi mô hình

Phân tách dữ liệu. Tách 5% sản phẩm của tập huấn luyện FashionMV (không trùng sản phẩm với phần còn lại) làm **tập dev**, dùng cho chọn checkpoint, chọn siêu tham số (ρ , τ_c , λ_v , p_{vd}) và ngưỡng lọc. Tập validation công bố chỉ dùng để **báo cáo**, tránh rò rỉ thông tin khi điều chỉnh.

Khả dụng dữ liệu FashionIQ. Nhiều URL ảnh gốc của FashionIQ không còn truy cập được. Đề tài dùng bản sao công khai do cộng đồng lưu trữ, kiểm tra độ đầy đủ ở Tháng 1 và báo cáo rõ số triplet thực sự đánh giá được.

5.2 Phương pháp so sánh

Bảng 5: Các phương pháp đối chiếu

Phương pháp	Loại	Ý nghĩa so sánh
CLIP zero-shot (cộng embedding ảnh + văn bản; MeanPool trên góc nhìn)	Không huấn luyện	Mốc dưới cùng, chạy trong cùng hạ tầng trên FashionMV và FashionIQ
CLIP4Cir [6] + MeanPool/MaxSim	CIR đơn ảnh, tổng hợp hậu kỳ	Huấn luyện lại trong cùng hạ tầng trên tập con FashionMV (mốc dưới cho truy xuất mức sản phẩm) và trên FashionIQ (mốc tham chiếu trong miền cho G3)
ProCIR (checkpoint công khai)	Kiểm tra pipeline	Chỉ dùng để xác minh pipeline đánh giá tái tạo đúng số liệu công bố; không tham gia kết luận
ProCIR (tái lập)	Multi-View CIR	Baseline chính, tái lập ở quy mô 1 GPU
ProCIR + View-Aware Selection	Đề xuất (một phần)	Định lượng riêng đóng góp G1
ProCIR + Hard Negatives	Đề xuất (một phần)	Định lượng riêng đóng góp G5
MV-SHN (đầy đủ)	Đề xuất	Kiểm định tính hỗ trợ của hai cơ chế
MV-SHN + view-dropout huấn luyện	Đề xuất (mở rộng)	Kiểm định cải thiện độ bền G2
TIRG, CoSMo, ARTEMIS, FashionVLP	Số liệu công bố	Chỉ trình bày để tham khảo bối cảnh trên FashionIQ; không so sánh trực tiếp do khác quy mô huấn luyện

5.3 Ablation Study

Bảng 6: Các biến thể ablation

Biến thể	Mục đích kiểm định
Có / không View-Aware Selection	Đóng góp của G1 (Recall và VHR)
VAS: phần dư khởi tạo 0 / hợp nhất không đường tắt (MLP trên $[h_{\text{emb}}; W_o \bar{s}]$)	Kiểm tra module mới có phá vỡ biểu diễn đã học hay không
VAS: có / không giám sát yếu $\mathcal{L}_{\text{view}}$	Tác dụng của nhãn góc nhìn tự động
Số mẫu âm khó $ \mathcal{H} $: 0 / 2 / 4 / 8	Đường cong lợi ích và điểm bão hoà của G5
Mẫu âm khó: có lọc / không lọc mẫu âm giả	Tác động của mẫu âm giả
View-dropout khi huấn luyện: có / không	Cải thiện độ bền G2



Biến thể	Mục đích kiểm định
Số góc nhìn khi suy luận: 1 / 2 / 3 / 5	Độ bền theo số góc nhìn (G2); mức 5 là ngoại suy vượt số góc tối đa khi huấn luyện (3)
LoRA / full fine-tune (pilot, 5% dữ liệu)	Kiểm chứng lựa chọn LoRA ở Mục 5.5

5.4 Đánh giá đo lường

- **Chỉ số chính:** Recall@5 và Recall@10 trên ba tập validation của FashionMV, dùng văn bản điều chỉnh bản ngắn, đúng giao thức của công trình gốc.
- **Chẩn đoán và diễn giải (G1):** VHR của baseline (theo A_i) và của module đề xuất (theo α_i), cùng trực quan hoá α_i trên các ví dụ tiêu biểu.
- **Độ bền (G2):** Recall@5/@10 theo số góc nhìn khả dụng khi suy luận, mô phỏng bằng view-dropout ngẫu nhiên, lặp 5 lần lấy mẫu góc nhìn.
- **Chuyển giao (G3):** Recall@10/@50 trên FashionIQ theo giao thức chuẩn (trung bình ba danh mục Dress, Shirt, Toottee). Mô hình huấn luyện trên FashionMV được đánh giá **zero-shot transfer** (không tinh chỉnh trên FashionIQ). Đại lượng quan tâm là khoảng cách so với CLIP zero-shot và CLIP4Cir huấn luyện trong miền FashionIQ, cả hai chạy trong cùng hạ tầng.

Giới hạn của phép đánh giá G3: FashionIQ là benchmark một ảnh tham khảo ($N_P = 1$), nên phép đánh giá này kiểm chứng khả năng khái quát hoá theo văn phong mô tả do người viết (thay vì do mô hình sinh), nhưng không kiểm chứng được module View-Aware Selection trên góc nhìn ngoài phân bố huấn luyện, vì FashionIQ không có cấu trúc đa góc để lựa chọn.

Độ tin cậy thống kê: Các so sánh chính (baseline tái lập so với MV-SHN đầy đủ) lặp lại với 3 random seed, báo cáo trung bình $\pm$ độ lệch chuẩn. **Mọi** so sánh, kể cả biến thể ablation chạy 1 seed, được kiểm định bằng **paired bootstrap** trên tập truy vấn [29]: lấy mẫu lại có hoàn lại 1.000 lần, tính khoảng tin cậy 95% của $\Delta \text{Recall@K}$; chênh lệch được coi là có ý nghĩa khi khoảng tin cậy không chứa 0. Phép kiểm định này gần như không tốn chi phí tính toán. Seed bổ sung chỉ chạy khi ngân sách dự phòng cho phép và hai biến thể liên kế có khoảng tin cậy chồng lấp.

5.5 Cấu hình thực nghiệm trên tài nguyên hạn chế

Công trình gốc huấn luyện một epoch trên 188K triplet bằng 10 GPU RTX 3090, mất khoảng 7 giờ 20 phút đến 14 giờ 33 phút tùy cấu hình, tương đương 73–145 GPU-giờ cho một cấu hình. Với một GPU đơn, tái lập nguyên trạng là bất khả thi trong một học kỳ. Đề tài áp dụng các điều chỉnh sau và **báo cáo minh bạch rằng mọi so sánh đều thực hiện ở quy mô thu gọn**:

Bảng 7: Điều chỉnh cấu hình cho một GPU đơn

Hạng mục	Công trình gốc	Đề tài (1 GPU)
Phần cứng	10×RTX 3090	1×RTX 3090/4090 (24GB)
Tinh chỉnh	Full fine-tune	LoRA [28] (kiểm chứng bằng pilot so với full fine-tune)
Dữ liệu huấn luyện	188K triplet	20–30% tập huấn luyện, lấy mẫu cân bằng theo ba nguồn



Hạng mục	Công trình gốc	Đề tài (1 GPU)
Batch contrastive	160	64, đạt được nhờ GradCache (không dùng gradient accumulation cho mục đích này)
Mẫu âm mỗi truy vấn	159 (in-batch)	63 in-batch + $ \mathcal{H} $ mẫu âm khó của chính truy vấn + mẫu âm khó của các truy vấn khác trong batch
Số góc nhìn tối đa	5	3 (giữ trước + sau + một góc bổ sung)
Độ phân giải ảnh tối đa	512×512	336×336
Khởi tạo	Có tùy chọn SFT	Bỏ SFT; baseline và mọi biến thể khởi tạo từ cùng checkpoint Qwen3.5-0.8B gốc. Checkpoint ProCIR công khai chỉ dùng kiểm tra pipeline đánh giá
Tập chọn mô hình	–	Tập dev tách từ train (5% sản phẩm)

Lý do chọn LoRA. Với 0,8B tham số, full fine-tune bằng AdamW mixed precision cần khoảng 16 byte/tham số ($\approx 13\text{GB}$) cho tham số, gradient và trạng thái optimizer, chỉ còn $\approx 11\text{GB}$ cho activation. Nút thắt thực sự là activation của nhiều ảnh mỗi mẫu. LoRA giải phóng phần lớn bộ nhớ optimizer, cho phép chunk GradCache lớn hơn và huấn luyện nhanh hơn. Lựa chọn này được kiểm chứng bằng pilot LoRA/full fine-tune trên 5% dữ liệu ở Tháng 2.

Lưu ý về diễn giải kết quả: do quy mô thu gọn, con số tuyệt đối sẽ thấp hơn công bố gốc. Mọi kết luận của đề tài dựa trên **so sánh tương đối** giữa các phương pháp chạy trong cùng một cấu hình tài nguyên, không so trực tiếp với số liệu in trong bài báo.

5.6 Ngân sách tính toán

Ước lượng chi phí một epoch. Xuất phát từ 73–145 GPU-giờ (3090) của công trình gốc, áp dụng các hệ số: dữ liệu 25% ($\times 0,25$); số visual token giảm do độ phân giải $(336/512)^2 \approx 0,43$ và số góc nhìn $3/3,7 \approx 0,8$ (gộp $\approx \times 0,35$); LoRA giảm chi phí lan truyền ngược ($\approx \times 0,75$). Kết quả $\approx 5\text{--}10$ GPU-giờ/epoch cho truy vấn + mẫu dương. GradCache thêm một lượt forward ($\approx \times 1,35$): **7–13 GPU-giờ**. Mỗi mẫu âm khó thêm một sản phẩm cần mã hoá; với $|\mathcal{H}| = 2$, số sản phẩm mã hoá mỗi triplet tăng từ 2 lên 4: **13–26 GPU-giờ**. Đây là ước lượng ngoại suy; thời gian thực tế mỗi step sẽ được đo bằng pilot ở Tháng 1 và bảng dưới được hiệu chỉnh trong báo cáo giữa kỳ.

Bảng 8: Ngân sách GPU-giờ dự kiến (cận trên, 1 epoch mỗi run)

Hạng mục	Số run	GPU-giờ/run	Tổng
Pilot đo tốc độ, kiểm tra pipeline	3	3	9
Pilot LoRA / full fine-tune (5% dữ liệu)	2	3	6
CLIP4Cir (FashionMV, FashionIQ)	2	5	10
Baseline ProCIR tái lập	3	13	39
ProCIR + VAS	1	14	14
ProCIR + HN ($ \mathcal{H} = 2$)	1	26	26
MV-SHN đầy đủ	3	27	81



Hạng mục	Số run	GPU-giờ/run	Tổng
Quét $ \mathcal{H} = 4, 8$	2	39 / 65	104
HN không lọc	1	26	26
VAS không phần dư; VAS + $\mathcal{L}_{\text{view}}$	2	14	28
View-dropout khi huấn luyện	1	25	25
Suy luận: G2, G3, VHR, bootstrap	–	–	10
Tổng			378
Dự phòng 30% (seed bổ sung, chạy lại)			113
Tổng cộng			≈ 490

Ba tháng TT2 tương đương khoảng 1.800 GPU-giờ nếu GPU chạy liên tục 20 giờ/ngày; với hiệu suất sử dụng thực tế 50% (≈ 900 GPU-giờ), ngân sách ≈ 490 GPU-giờ vẫn khả thi. Nếu pilot cho thấy chi phí vượt ước lượng, run $|\mathcal{H}| = 8$ chuyển sang chế độ embedding mẫu âm lưu đệm không gradient (làm mới mỗi 1/4 epoch), giảm chi phí run này xuống khoảng 15 GPU-giờ.

6 Kế hoạch thực hiện

Bảng 9: Kế hoạch thực hiện theo tháng

Giai đoạn	Thời gian	Nội dung chính
TT1	Tháng 1	Hoàn thiện Literature Review (cập nhật khảo sát tính đến thời điểm báo cáo). Tải và khảo sát FashionMV: phân bố số ảnh/sản phẩm, tỉ lệ sản phẩm 1–2 ảnh, metadata góc chụp. Mốc go/no-go G5 : kiểm tra dữ liệu công bố có kèm nhóm ứng viên bị loại hay không; nếu không, khởi động tái tạo ngay. Tải và kiểm tra độ đầy đủ ảnh FashionIQ. Dựng môi trường huấn luyện 1 GPU tích hợp GradCache; chạy pilot đo tốc độ và hiệu chỉnh ngân sách.
	Tháng 2	Tái lập ProCIR ở quy mô thu gọn; kiểm tra pipeline đánh giá bằng checkpoint công khai. Cài đặt CLIP zero-shot và CLIP4Cir + MeanPool/MaxSim. Pilot LoRA/full fine-tune. Gán nhãn gốc nhìn (CLIP zero-shot + 200 ảnh thủ công) và luật từ khoá cho văn bản.
	Tháng 3	Thí nghiệm chẩn đoán VHR của baseline, áp dụng quy tắc quyết định ở Mục 4.3.1. Xây kho mẫu âm khó, áp dụng lọc (F1)+(F2). Báo cáo giữa kỳ TT1 : thống kê dữ liệu, VHR baseline, ngân sách GPU đã hiệu chỉnh, kết quả baseline.
TT2	Tháng 4	Hiện thực nhánh mẫu âm khó (ưu tiên G5 theo Bảng 10); huấn luyện ProCIR + HN; quét $ \mathcal{H} $; biến thể không lọc.
	Tháng 5	Hiện thực View-Aware Selection và các biến thể (phần dư, giám sát yếu); huấn luyện MV-SHN đầy đủ (3 seed).



Giai đoạn	Thời gian	Nội dung chính
	Tháng 6	Thực nghiệm độ bền G2 (suy luận 1/2/3/5 góc; view-dropout khi huấn luyện); đánh giá chuyển giao FashionIQ (G3); phân tích VHR và trọng số α_i . Bắt đầu viết chương Phương pháp và Thực nghiệm song song.
	Tháng 7	Hoàn thiện báo cáo/bài báo, kiểm định thống kê cuối cùng, chuẩn bị và bảo vệ.

7 Rủi ro và Phương án dự phòng

Bảng 10: Phân tích rủi ro và phương án dự phòng

Rủi ro	Mức độ	Phương án dự phòng
Tài nguyên 1 GPU không đủ hoàn tất ablation trong TT2	Cao	Ưu tiên G5 $\rightarrow$ G1 $\rightarrow$ G2 $\rightarrow$ G3; giảm dữ liệu xuống 10%; biến thể phụ chạy 1 seed kèm paired bootstrap; run $ \mathcal{H} = 8$ dùng embedding lưu đệm
Nhóm ứng viên bị loại không được công bố kèm dataset	Cao	Phát hiện sớm nhờ mốc go/no-go Tháng 1. Tái tạo nhóm ứng viên bằng cách chạy lại bước truy hồi láng giềng theo mô tả trong bài báo (tương đồng thị giác và caption), hoặc khai thác mẫu âm khó từ embedding của baseline
Mẫu âm giả trong nhóm ứng viên bị loại	Trung bình	Lọc hai tầng (F1)+(F2); ablation có/không lọc; dự phòng debiased contrastive loss
VHR baseline đã cao, G1 yếu	Trung bình	Áp dụng quy tắc quyết định định trước; định vị lại G1 theo hướng diễn giải và giám sát yếu; báo cáo như một phát hiện về ProCIR
Nhân góc nhìn tự động không đủ tin cậy	Trung bình	Kiểm định trên 200 ảnh thủ công; nếu độ chính xác $< 85\%$, chỉ dùng tập con có metadata hoặc có từ khóa rõ ràng
Ảnh FashionIQ không đầy đủ	Trung bình	Dùng bản sao công khai; báo cáo trên tập con khả dụng kèm số lượng triplet thực tế
Module View-Aware Selection làm giảm hiệu năng	Thấp	Kết nối phần dư khởi tạo bằng 0 đảm bảo điểm xuất phát trùng baseline; nếu vẫn xấu, báo cáo như phát hiện thực nghiệm kèm phân tích α_i
Kết quả tái lập cách xa số liệu công bố do thu gọn quy mô	Trung bình	Mọi kết luận dựa trên so sánh tương đối trong cùng cấu hình; checkpoint công khai dùng để xác minh pipeline đánh giá
Lỗi ảo giác trái/phải (G4) gây nhiễu đánh giá	Thấp	Không đặt G4 làm đóng góp; khảo sát định tính trên mẫu nhỏ và ghi nhận như giới hạn dữ liệu nền

8 Dự kiến sản phẩm bàn giao và Ý nghĩa

8.1 Sản phẩm bàn giao

1. Checkpoint mô hình MV-SHN và baseline ProCIR tái lập ở quy mô 1 GPU.
2. Mã nguồn nghiên cứu tái lập được (tích hợp GradCache), kèm cấu hình cho toàn bộ biến thể ablation.
3. Bộ mẫu âm khó trích xuất/tái tạo từ pipeline FashionMV, đã lọc mẫu âm giả – tài nguyên có thể dùng lại cho nghiên cứu sau.
4. Bộ nhãn góc nhìn tự động, luật gán góc mục tiêu cho văn bản và công cụ tính VHR.
5. Báo cáo thực nghiệm: bảng Recall@5/@10 kèm khoảng tin cậy bootstrap, đường cong độ bền theo số góc nhìn, kết quả chuyển giao FashionIQ, ngân sách GPU thực tế.
6. Báo cáo khóa luận kèm phân tích định tính trọng số góc nhìn.

8.2 Ý nghĩa khoa học và thực tiễn

- **Khoa học:** Cung cấp phân tích chẩn đoán đầu tiên về cách ProCIR lựa chọn góc nhìn; bổ sung cơ chế lựa chọn góc nhìn tường minh cho bài toán Multi-View CIR; đồng thời cung cấp hai đánh giá mà công trình gốc chưa thực hiện (độ bền theo số góc nhìn và chuyển giao sang benchmark do người gán nhãn), góp phần kiểm chứng độc lập một bài toán vừa được đề xuất.
- **Thực tiễn:** Kết quả về độ bền khi thiếu góc nhìn có giá trị triển khai trực tiếp đối với các catalog có nhiều SKU thiếu ảnh đa góc (mức độ phổ biến trên FashionMV được định lượng ở Tháng 1). Việc kết hợp GradCache và mẫu âm khó giúp huấn luyện khả thi trên hạ tầng một GPU – phù hợp với điều kiện của phần lớn nhóm nghiên cứu và doanh nghiệp vừa và nhỏ tại Việt Nam.

8.3 Hướng mở rộng ứng dụng (ngoài phạm vi đánh giá chính)

Nếu MV-SHN đạt kết quả khả quan, hướng mở rộng tự nhiên là lập chỉ mục biểu diễn sản phẩm đích bằng Approximate Nearest Neighbor (ví dụ FAISS [19] hoặc HNSW [20]) phục vụ tra cứu trên catalog nhiều SKU của B2B buyers. Thiết kế giữ biểu diễn đích độc lập với truy vấn (Mục 4.3.2) chính là điều kiện để chỉ mục được xây một lần và dùng lại; module View-Aware Selection chỉ chạy phía truy vấn tại thời điểm tra cứu. Việc thiết kế đầy đủ một hệ thống Backend production (API Gateway, đồng bộ dữ liệu thời gian thực, SLA về độ trễ/thông lượng) nằm ngoài phạm vi đề tài và có thể là chủ đề của một đề tài kỹ thuật hệ thống riêng.

9 Tài liệu tham khảo

- [1] Yuan, P., Mei, B., & Zhang, H. (2026). FashionMV: Product-level composed image retrieval with multi-view fashion data. *arXiv preprint arXiv:2604.10297*.
- [2] Vo, N., Jiang, L., Sun, C., Murphy, K., Li, L.-J., Fei-Fei, L., & Hays, J. (2019). Composing text and image for image retrieval – an empirical odyssey. *CVPR*, 6439–6448.
- [3] Lee, S., Kim, D., & Han, B. (2021). CoSMo: Content-style modulation for image retrieval with text feedback. *CVPR*, 802–812.
- [4] Delmas, G., Rezende, R.S., Csurka, G., & Larlus, D. (2022). ARTEMIS: Attention-based retrieval with text-explicit matching and implicit similarity. *ICLR*.

- [5] Radford, A., Kim, J.W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., Sastry, G., Askell, A., Mishkin, P., Clark, J., Krueger, G., & Sutskever, I. (2021). Learning transferable visual models from natural language supervision. *ICML*.
- [6] Baldrati, A., Bertini, M., Uricchio, T., & Del Bimbo, A. (2022). Effective conditioned and composed image retrieval combining CLIP-based features. *CVPR*, 21466–21474.
- [7] Goenka, S., Zheng, Z., Jaiswal, A., Chada, R., Wu, Y., Hedau, V., & Natarajan, P. (2022). FashionVLP: Vision language transformer for fashion retrieval with feedback. *CVPR*, 14105–14115.
- [8] Chia, P.J., Attanasio, G., Bianchi, F., Terragni, S., Magalhães, A.R., Goncalves, D., Greco, C., & Tagliabue, J. (2022). Contrastive language and vision learning of general fashion concepts (Fashion-CLIP). *Scientific Reports*, 12(1).
- [9] Han, X., Yu, L., Zhu, X., Zhang, L., Song, Y.-Z., & Xiang, T. (2022). FashionViL: Fashion-focused vision-and-language representation learning. *ECCV*.
- [10] Saito, K., Sohn, K., Zhang, X., Li, C.-L., Lee, C.-Y., Saenko, K., & Pfister, T. (2023). Pic2Word: Mapping pictures to words for zero-shot composed image retrieval. *CVPR*, 19305–19314.
- [11] Baldrati, A., Agnolucci, L., Bertini, M., & Del Bimbo, A. (2023). Zero-shot composed image retrieval with textual inversion. *ICCV*, 15338–15347.
- [12] Gu, G., Chun, S., Kim, W., Kang, Y., & Yun, S. (2024). Language-only training of zero-shot composed image retrieval. *CVPR*, 13225–13234.
- [13] Huynh, C., Yang, J., Tawari, A., Shah, M., Tran, S., Hamid, R., Chilimbi, T., & Shrivastava, A. (2025). CoLLM: A large language model for composed image retrieval. *CVPR*, 3994–4004.
- [14] Wu, H., Gao, Y., Guo, X., Al-Halah, Z., Rennie, S., Grauman, K., & Feris, R. (2021). Fashion IQ: A new dataset towards retrieving images by natural language feedback. *CVPR*, 11307–11317.
- [15] Gardères, F., Chen, S., Gauthier, C.-S., & Ponce, J. (2025). FACap: A large-scale fashion dataset for fine-grained composed image retrieval. *arXiv preprint arXiv:2507.07135*.
- [16] Liu, Z., Luo, P., Qiu, S., Wang, X., & Tang, X. (2016). DeepFashion: Powering robust clothes recognition and retrieval with rich annotations. *CVPR*, 1096–1104.
- [17] Han, X., Wu, Z., Huang, P.X., Zhang, X., Zhu, M., Li, Y., Zhao, Y., & Davis, L.S. (2017). Automatic spatially-aware fashion concept discovery. *ICCV*, 1472–1480.
- [18] Rostamzadeh, N., Hosseini, S., Boquet, T., Stokowiec, W., Zhang, Y., Jauvin, C., & Pal, C. (2018). Fashion-Gen: The generative fashion dataset and challenge. *arXiv preprint arXiv:1806.08317*.
- [19] Johnson, J., Douze, M., & Jégou, H. (2021). Billion-scale similarity search with GPUs. *IEEE Transactions on Big Data*, 7(3), 535–547.
- [20] Malkov, Y.A., & Yashunin, D.A. (2020). Efficient and robust approximate nearest neighbor search using hierarchical navigable small world graphs. *IEEE TPAMI*, 42(4), 824–836.
- [21] Gardères, F., et al. (2026). FIRE-CIR: Fine-grained reasoning for composed fashion image retrieval. *CVPR 2026; arXiv preprint arXiv:2604.09114*.
- [22] Li, Z., Fu, Z., Hu, Y., Chen, Z., Wen, H., & Nie, L. (2025). FineCIR: Explicit parsing of fine-grained modification semantics for composed image retrieval. *arXiv preprint arXiv:2503.21309*.
- [23] Gao, L., Zhang, Y., Han, J., & Callan, J. (2021). Scaling deep contrastive learning batch size under memory limited setup. *Proceedings of the 6th Workshop on Representation Learning for NLP (RepL4NLP)*.
- [24] He, K., Fan, H., Wu, Y., Xie, S., & Girshick, R. (2020). Momentum contrast for unsupervised visual representation learning. *CVPR*, 9729–9738.



- [25] Robinson, J., Chuang, C.-Y., Sra, S., & Jegelka, S. (2021). Contrastive learning with hard negative samples. *ICLR*.
- [26] Chuang, C.-Y., Robinson, J., Lin, Y.-C., Torralba, A., & Jegelka, S. (2020). Debiased contrastive learning. *NeurIPS*, 33.
- [27] Moreira, G. de S. P., Osmulski, R., Xu, M., Ak, R., Schifferer, B., & Oldridge, E. (2024). NV-Retriever: Improving text embedding models with effective hard-negative mining. *arXiv preprint arXiv:2407.15831*.
- [28] Hu, E.J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., & Chen, W. (2022). LoRA: Low-rank adaptation of large language models. *ICLR*.
- [29] Koehn, P. (2004). Statistical significance tests for machine translation evaluation. *EMNLP*, 388–395.
- [30] Zhang, R., Han, J., Liu, C., Zhou, A., Lu, P., Qiao, Y., Li, H., & Gao, P. (2024). LLaMA-Adapter: Efficient fine-tuning of large language models with zero-initialized attention. *ICLR*.